



(21) 申请号 202411059877.8

(22) 申请日 2024.08.05

(71) 申请人 山东工商学院

地址 264003 山东省烟台市莱山区滨海中路191号

(72) 发明人 孙静 翟千淳

(74) 专利代理机构 淄博市众朗知识产权代理事务所(特殊普通合伙) 37316

专利代理师 程强强

(51) Int. Cl.

G01R 31/378 (2019.01)

G01R 31/367 (2019.01)

G01R 31/392 (2019.01)

权利要求书3页 说明书12页 附图1页

(54) 发明名称

基于融合特征的锂离子电池剩余使用寿命预测方法

(57) 摘要

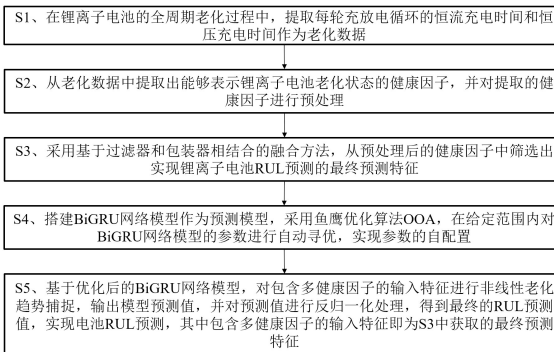
本发明属于电池剩余使用寿命预测技术领域,具体涉及基于融合特征的锂离子电池剩余使用寿命预测方法,步骤包括在锂离子电池的全周期老化过程中,提取每轮充放电循环的恒流充电时间和恒压充电时间作为老化数据;从老化数据中提取出能够表示锂离子电池老化状态的健康因子,并对提取的健康因子进行预处理;

S3、采用基于过滤器和包装器相结合的融合方法,从预处理后的健康因子中筛选出实现锂离子电池RUL预测的最终预测特征;

S4、搭建BiGRU网络模型作为预测模型,采用鱼鹰优化算法OOA,在给定范围内对BiGRU网络模型的参数进行自动寻优,实现参数的自配置;

S5、基于优化后的BiGRU网络模型,对包含多健康因子的输入特征进行非线性老化趋势捕捉,输出模型预测值,并对预测值进行反归一化处理,得到最终的RUL预测值,实现电池RUL预测,其中包含多健康因子的输入特征即为S3中获取的最终预测特征

解决了电池容量难以直接测量的问题,搭建的预测模型具有良好的准确性和鲁棒性,且能够有效防止模型过拟合。



1. 基于融合特征的锂离子电池剩余使用寿命预测方法,其特征包括以下步骤:

S1、在锂离子电池的全周期老化过程中,提取每轮充放电循环的恒流充电时间和恒压充电时间作为老化数据;

S2、从老化数据中提取出能够表示锂离子电池老化状态的健康因子,并对提取的健康因子进行预处理;

S3、采用基于过滤器和包装器相结合的融合方法,从预处理后的健康因子中筛选出实现锂离子电池RUL预测的最终预测特征;

S4、搭建BiGRU网络模型作为预测模型,采用鱼鹰优化算法00A,在给定范围内对BiGRU网络模型的参数进行自动寻优,实现参数的自配置;

S5、基于优化后的BiGRU网络模型,对包含多健康因子的输入特征进行非线性老化趋势捕捉,输出模型预测值,并对预测值进行反归一化处理,得到最终的RUL预测值,实现电池RUL预测,其中包含多健康因子的输入特征即为S3中获取的最终预测特征。

2. 根据权利要求1所述的基于融合特征的锂离子电池剩余使用寿命预测方法,其特征包括:所述的S2中,健康因子包括恒流充电时间、恒压充电时间以及基于锂离子电池恒流充电电压曲线提取的不同起始电压的等时间电压增量、不同电压变化区间的等电压上升时间、充电电压曲线斜率最低点斜率值、充电电压曲线斜率最低点时间和充电电压曲线斜率最低点电压值。

3. 根据权利要求1所述的基于融合特征的锂离子电池剩余使用寿命预测方法,其特征包括:所述的S2中,预处理包括:

采用 3σ 原则,将偏离均值超过3个标准差的数据点标记为异常值,删除该异常点对应循环次数的全部健康因子;

采用Savitzky-Golay滤波器,通过调整滑动窗口长度和多项式阶数来适应不同健康因子的特点,对异常值处理后的健康因子进行平滑处理。

4. 根据权利要求3所述的基于融合特征的锂离子电池剩余使用寿命预测方法,其特征包括:对于Savitzky-Golay滤波器,定义自适应窗口调整公式为:

窗口长度=基础窗口长度 $\times (1+\theta \times \text{信号频率})$;

其中, θ 是根据信号特性调整的系数。

5. 根据权利要求1所述的基于融合特征的锂离子电池剩余使用寿命预测方法,其特征包括:所述的S3中,从预处理后的健康因子中筛选出实现锂离子电池RUL预测的最终预测特征的方法为:

S31、采用基于过滤器方法的Pearson相关性分析,对预处理后的健康因子,进行关联度评估,计算出不同健康因子与电池老化状态之间的关联程度,根据Pearson相关系数的高低,选择出相关性最高的四个健康因子作为初步筛选后的特征,同时过滤掉其余健康因子;

S32、采用序列前向搜索方法,识别并获取不同健康因子组合的特征空间,找出最优的用于RUL预测的特征组合,即为实现锂离子电池RUL预测的最终预测特征。

6. 根据权利要求5所述的基于融合特征的锂离子电池剩余使用寿命预测方法,其特征包括:将获得的用于RUL预测的特征组合按照充放电循环周期数平均分为两部分,前50%数据作为训练集,用于预测模型的搭建,后50%数据作为测试集,用于验证预测模型的准确性和鲁棒性。

7. 根据权利要求1所述的基于融合特征的锂离子电池剩余使用寿命预测方法,其特征
在于:所述的S4中,搭建BiGRU网络模型的方法为:

S41、使用python语言,搭建tensorflow环境,建立BiGRU网络模型,BiGRU网络模型包括
输入层、BiGRU层、Dropout层和输出层,其中BiGRU层和Dropout层均采用双层结构;

S42、将筛选出的最终预测特征归一化后,输入到BiGRU网络模型中,并设置BiGRU网络
模型的参数;

S43、训练BiGRU网络模型,手动调整参数直到BiGRU网络模型达到设定的预测效果,训
练过程中,采用Adam优化器来自动调整BiGRU网络模型的学习率,利用均方误差作为BiGRU
网络模型反向传播的损失函数,在对BiGRU网络模型训练的过程中提供稳定的误差梯度;

S44、保存训练后的BiGRU网络模型;

S45、对于保存的BiGRU网络模型,基于鱼鹰优化算法00A,在给定范围内对BiGRU网络模
型的参数进行自动寻优,实现参数的自配置。

8. 根据权利要求7所述的基于融合特征的锂离子电池剩余使用寿命预测方法,其特征
在于:所述的S43中,引入基于模型预测误差变化的学习率调整机制来自动调整BiGRU网络
模型的学习率,表示为:

$$\eta_{t+1} = \eta_t \cdot e^{-\alpha \cdot |\text{MSE}_t - \text{MSE}_{t-1}|};$$

式中, η_{t+1} 是调整后的学习率; η_t 是当前时刻的学习率; MSE_t 是当前时刻的均方误差;
 MSE_{t-1} 是上一时刻的均方误差; α 是调整速度的超参数; e 是自然常数;

同时,引入基于时间序列特性的损失函数作为均方误差损失函数的补充,基于时间序
列特性的损失函数Time_Dependent_Loss表示为:

$$\text{Time_Dependent_Loss} = \sum_{i=1}^n [(y_i - \hat{y}_i)^2 + \delta \cdot |y_{i+1} - \hat{y}_i - \hat{y}_{i-1}|];$$

式中, y_i 是时间点*i*的实际值; y_{i+1} 是后一个时间点*i+1*的实际值; $\hat{y}_{i-1}$ 是前一个时间点
*i-1*的预测值; $\hat{y}_i$ 是时间点*i*的预测值; δ 是调节系数,用于控制时间依赖性对总损失的贡献;
*i*表示时间点; n 是时间点的数量;基于时间序列特性的损失函数考虑前一个时间点*i-1*和后
一个时间点*i+1*的值,从而捕捉时间序列的连续性和趋势;

并且,利用训练BiGRU网络模型过程中的训练集和验证集,动态调整Dropout层的
Dropout率,表示为:

$$p_{\text{Dropout},t+1} = p_{\text{Dropout},t} + \beta \cdot (\text{Val_MSE}_t - \text{Train_MSE}_t);$$

式中, $p_{\text{Dropout},t}$ 是当前时刻的Dropout率; $p_{\text{Dropout},t+1}$ 是调整后的Dropout率;
 Val_MSE_t 是验证集上的均方误差; Train_MSE_t 是训练集上的均方误差; β 是调整步长。

9. 根据权利要求7所述的基于融合特征的锂离子电池剩余使用寿命预测方法,其特征
在于:所述的S45中,采用00A实现参数自配置的过程为:

S451、根据S43中手动调整的参数结果,设定00A的搜索范围;

S452、在设定好的搜索范围内初始化鱼鹰种群中个体的位置;

S453、以均方根误差作为适应度函数,计算每个个体的适应度值;

S454、根据鱼鹰捕食搜索策略更新个体位置,若更新后的位置超出边界则将位置停留

在边界处;

S455、判断更新后的个体适应度是否小于更新前的个体适应度,若小于则更新个体的位置,否则保留个体更新前的位置;

S456、判断是否达到结束条件,若达到结束条件,则返回搜索到的最优参数组合配置到BiGRU网络模型中,否则进行下一轮的迭代搜索。

10.根据权利要求1所述的基于融合特征的锂离子电池剩余使用寿命预测方法,其特征在于:将优化后的BiGRU网络模型集成到电池管理系统BMS中,实现实时监控和预测。

基于融合特征的锂离子电池剩余使用寿命预测方法

技术领域

[0001] 本发明属于电池剩余使用寿命预测技术领域,具体涉及基于融合特征的锂离子电池剩余使用寿命预测方法。

背景技术

[0002] 锂离子电池因其具有高能量密度、低自然放电率、长使用寿命、绿色清洁等优势,被广泛用作新能源汽车的动力电池。然而,锂离子电池在使用的过程中随着环境温度的变化和循环充放电次数的累积,其容量会不断衰退,内阻持续增加,进而影响电池的续航能力和功率输出。长期使用会导致电池的充电速度变慢,续航里程缩短,严重老化的电池甚至可能出现膨胀、漏液或热失控等安全风险。通过准确预测电池剩余使用寿命(Remaining Useful Life, RUL),电池管理系统(Battery Management System, BMS)能够提示用户及时对电池进行维护检查或更换,从而避免潜在安全事故的发生,确保电池和设备的长期稳定运行。这里所提的RUL指的是电池使用过程中以充放电循环次数为单位的剩余循环寿命,表示电池容量降低到规定失效阈值之前的剩余可用充放电循环次数。

[0003] 目前已有的RUL预测方法主要分为基于机理模型的方法和基于数据驱动的方法。基于机理模型的方法通过深入分析和理解电池内部的结构变化和失效机理,以及电池在不同工作条件下的行为和外在特性的变化,来构建反映电池老化状态的数学模型,但准确描述电池内部的多种电化学反应和物理过程的复杂性使得模型的建立和参数估计变得困难且耗时。基于数据驱动的预测方法不直接依赖于对电池内部物理或化学机理的深入了解,而是通过分析电池在过去的表现来预测其将来的性能,通过历史数据和先进的算法从电池的使用数据中学习和识别电池衰退的模式和趋势,从而预测电池的未来状态和寿命。

[0004] 然而数据驱动方法的算法中通常包含多个可调参数,这些参数的选择对预测性能有显著影响。合适的参数设置往往需要依赖专业知识并通过不断调试来确定,这增加了模型设定的复杂性。同时,现有的数据驱动方法中大多使用历史容量数据实现锂离子电池RUL预测,而BMS在新能源汽车的使用过程中难以对容量做出直接测量,降低了方法的现实应用价值。

发明内容

[0005] 根据以上现有技术中的不足,本发明提供了基于融合特征的锂离子电池剩余使用寿命预测方法,解决了电池容量难以直接测量的问题,搭建的预测模型具有良好的准确性和鲁棒性,且能够有效防止模型过拟合。

[0006] 为达到以上目的,本发明提供了基于融合特征的锂离子电池剩余使用寿命预测方法,包括以下步骤:

S1、在锂离子电池的全周期老化过程中,提取每轮充放电循环的恒流充电时间和恒压充电时间作为老化数据;

S2、从老化数据中提取出能够表示锂离子电池老化状态的健康因子,并对提取的

健康因子进行预处理；

S3、采用基于过滤器和包装器相结合的融合方法，从预处理后的健康因子中筛选出实现锂离子电池RUL预测的最终预测特征；

S4、搭建BiGRU网络模型作为预测模型，采用鱼鹰优化算法00A，在给定范围内对BiGRU网络模型的参数进行自动寻优，实现参数的自配置；

S5、基于优化后的BiGRU网络模型，对包含多健康因子的输入特征进行非线性老化趋势捕捉，输出模型预测值，并对预测值进行反归一化处理，得到最终的RUL预测值，实现电池RUL预测，其中包含多健康因子的输入特征即为S3中获取的最终预测特征。

[0007] 所述的S2中，健康因子包括恒流充电时间、恒压充电时间以及基于锂离子电池恒流充电电压曲线提取的不同起始电压的等时间电压增量、不同电压变化区间的等电压上升时间、充电电压曲线斜率最低点斜率值、充电电压曲线斜率最低点时间和充电电压曲线斜率最低点电压值。

[0008] 所述的S2中，预处理包括：

采用 3σ 原则，将偏离均值超过3个标准差的数据点标记为异常值，删除该异常点对应循环次数的全部健康因子；

采用Savitzky-Golay滤波器，通过调整滑动窗口长度和多项式阶数来适应不同健康因子的特点，对异常值处理后的健康因子进行平滑处理。

[0009] 对于Savitzky-Golay滤波器，定义自适应窗口调整公式为：

窗口长度=基础窗口长度 $\times (1+\theta \times \text{信号频率})$ ；

其中， θ 是根据信号特性调整的系数。

[0010] 所述的S3中，从预处理后的健康因子中筛选出实现锂离子电池RUL预测的最终预测特征的方法为：

S31、采用基于过滤器方法的Pearson相关性分析，对预处理后的健康因子，进行关联度评估，计算出不同健康因子与电池老化状态之间的关联程度，根据Pearson相关系数的高低，选择出相关性最高的四个健康因子作为初步筛选后的特征，同时过滤掉其余健康因子；

S32、采用序列前向搜索方法，识别并获取不同健康因子组合的特征空间，找出最优的用于RUL预测的特征组合，即为实现锂离子电池RUL预测的最终预测特征。

[0011] 将获得的用于RUL预测的特征组合按照充放电循环周期数平均分为两部分，前50%数据作为训练集，用于预测模型的搭建，后50%数据作为测试集，用于验证预测模型的准确性和鲁棒性。

[0012] 所述的S4中，搭建BiGRU网络模型的方法为：

S41、使用python语言，搭建tensorflow环境，建立BiGRU网络模型，BiGRU网络模型包括输入层、BiGRU层、Dropout层和输出层，其中BiGRU层和Dropout层均采用双层结构；

S42、将筛选出的最终预测特征归一化后，输入到BiGRU网络模型中，并设置BiGRU网络模型的参数；

S43、训练BiGRU网络模型，手动调整参数直到BiGRU网络模型达到设定的预测效果，训练过程中，采用Adam优化器来自动调整BiGRU网络模型的学习率，利用均方误差作为BiGRU网络模型反向传播的损失函数，在对BiGRU网络模型训练的过程中提供稳定的误差梯

度;

S44、保存训练后的BiGRU网络模型;

S45、对于保存的BiGRU网络模型,基于鱼鹰优化算法OOA,在给定范围内对BiGRU网络模型的参数进行自动寻优,实现参数的自配置。

[0013] 所述的S43中,引入基于模型预测误差变化的学习率调整机制来自动调整BiGRU网络模型的学习率,表示为:

$$\eta_{t+1} = \eta_t \cdot e^{-\alpha \cdot |\text{MSE}_t - \text{MSE}_{t-1}|};$$

式中, η_{t+1} 是调整后的学习率; η_t 是当前时刻的学习率; MSE_t 是当前时刻的均方误差; MSE_{t-1} 是上一时刻的均方误差; α 是调整速度的超参数; e 是自然常数;

同时,引入基于时间序列特性的损失函数作为均方误差损失函数的补充,基于时间序列特性的损失函数Time_Dependent_Loss表示为:

$$\text{Time_Dependent_Loss} = \sum_{i=1}^n [(y_i - \hat{y}_i)^2 + \delta \cdot |y_{i+1} - \hat{y}_i - \hat{y}_{i-1}|];$$

式中, y_i 是时间点*i*的实际值; y_{i+1} 是后一个时间点*i+1*的实际值; $\hat{y}_{i-1}$ 是前一个时间点*i-1*的预测值; $\hat{y}_i$ 是时间点*i*的预测值; δ 是调节系数,用于控制时间依赖性对总损失的贡献; i 表示时间点; n 是时间点的数量;基于时间序列特性的损失函数考虑前一个时间点*i-1*和后一个时间点*i+1*的值,从而捕捉时间序列的连续性和趋势;

并且,利用训练BiGRU网络模型过程中的训练集和验证集,动态调整Dropout层的Dropout率,表示为:

$$p_{\text{Dropout},t+1} = p_{\text{Dropout},t} + \beta \cdot (\text{Val_MSE}_t - \text{Train_MSE}_t);$$

式中, $p_{\text{Dropout},t}$ 是当前时刻的Dropout率; $p_{\text{Dropout},t+1}$ 是调整后的Dropout率; Val_MSE_t 是验证集上的均方误差; Train_MSE_t 是训练集上的均方误差; β 是调整步长。

[0014] 所述的S45中,采用OOA实现参数自配置的过程为:

S451、根据S43中手动调整的参数结果,设定OOA的搜索范围;

S452、在设定好的搜索范围内初始化鱼鹰种群中个体的位置;

S453、以均方根误差作为适应度函数,计算每个个体的适应度值;

S454、根据鱼鹰捕食搜索策略更新个体位置,若更新后的位置超出边界则将位置停留在边界处;

S455、判断更新后的个体适应度是否小于更新前的个体适应度,若小于则更新个体的位置,否则保留个体更新前的位置;

S456、判断是否达到结束条件,若达到结束条件,则返回搜索到的最优参数组合配置到BiGRU网络模型中,否则进行下一轮的迭代搜索。

[0015] 将优化后的BiGRU网络模型集成到电池管理系统BMS中,实现实时监控和预测。

[0016] 本发明涉及的算法可以通过电子设备执行,电子设备包括存储器、处理器及存储在存储器上并可在处理器上运行的计算机程序,通过处理器执行软件实现上述的算法。

[0017] 本发明所具有的有益效果是:

本发明通过采集电池老化过程中简单易测量的电流、电压和时间数据,并进一步

从中提取能反映电池老化趋势的健康因子,解决了电池容量难以直接测量的问题;提出一种结合过滤器与包装器的融合特征筛选策略,降低模型的复杂度,防止模型过拟合。

[0018] 本发明考虑到传统模型在处理多特征输入时捕捉电池老化信息的能力不足,将仅基于历史信息预测的GRU网络升级为能同时处理序列前向和后向信息的BiGRU网络,更加深入地理解序列整体结构和动态特性,更好地整合多维度特征,适应不同时间尺度的依赖关系。

[0019] 本发明采用00A对BiGRU模型内部的超参数进行有效的优化,提高了模型的预测精度,同时实现了参数的自动配置。实验结果表明,本发明在不同锂离子电池上均展现了良好的RUL预测效果,验证了本发明的准确性和鲁棒性。

附图说明

[0020] 图1是本发明的流程原理图。

具体实施方式

[0021] 下面结合附图对本发明的实施例做进一步描述:

如图1所示,基于融合特征的锂离子电池剩余使用寿命预测方法,包括以下步骤:

S1、在锂离子电池的全周期老化过程中,提取每轮充放电循环的恒流充电时间和恒压充电时间作为老化数据;

S2、从老化数据中提取出能够表示锂离子电池老化状态的健康因子,并对提取的健康因子进行预处理;

S3、采用基于过滤器和包装器相结合的融合方法,从预处理后的健康因子中筛选出实现锂离子电池RUL预测的最终预测特征;

S4、搭建BiGRU网络模型作为预测模型,采用鱼鹰优化算法00A,在给定范围内对BiGRU网络模型的参数进行自动寻优,实现参数的自配置;

S5、基于优化后的BiGRU网络模型,对包含多健康因子的输入特征进行非线性老化趋势捕捉,输出模型预测值,并对预测值进行反归一化处理,得到最终的RUL预测值,实现电池RUL预测,其中包含多健康因子的输入特征即为S3中获取的最终预测特征。

[0022] S2中,健康因子包括恒流充电时间、恒压充电时间以及基于锂离子电池恒流充电电压曲线提取的不同起始电压的等时间电压增量、不同电压变化区间的等电压上升时间、充电电压曲线斜率最低点斜率值、充电电压曲线斜率最低点时间和充电电压曲线斜率最低点电压值。

[0023] S2中,预处理包括:

采用 3σ 原则,将偏离均值超过3个标准差的数据点标记为异常值,删除该异常点对应循环次数的全部健康因子;

采用Savitzky-Golay滤波器,通过调整滑动窗口长度和多项式阶数来适应不同健康因子的特点,对异常值处理后的健康因子进行平滑处理。

[0024] 对于Savitzky-Golay滤波器,定义自适应窗口调整公式为:

窗口长度=基础窗口长度 $\times (1+\theta \times \text{信号频率})$;

其中, θ 是根据信号特性调整的系数。

[0025] S3中,从预处理后的健康因子中筛选出实现锂离子电池RUL预测的最终预测特征的方法为:

S31、采用基于过滤器方法的Pearson相关性分析,对预处理后的健康因子,进行关联度评估,计算出不同健康因子与电池老化状态之间的关联程度,根据Pearson相关系数的高低,选择出相关性最高的四个健康因子作为初步筛选后的特征,同时过滤掉其余健康因子;

S32、采用序列前向搜索方法,识别并获取不同健康因子组合的特征空间,找出最优的用于RUL预测的特征组合,即为实现锂离子电池RUL预测的最终预测特征。

[0026] 将获得的用于RUL预测的特征组合按照充放电循环周期数平均分为两部分,前50%数据作为训练集,用于预测模型的搭建,后50%数据作为测试集,用于验证预测模型的准确性和鲁棒性。

[0027] S4中,搭建BiGRU网络模型的方法为:

S41、使用python语言,搭建tensorflow环境,建立BiGRU网络模型,BiGRU网络模型包括输入层、BiGRU层、Dropout层和输出层,其中BiGRU层和Dropout层均采用双层结构;

S42、将筛选出的最终预测特征归一化后,输入到BiGRU网络模型中,并设置BiGRU网络模型的参数;

S43、训练BiGRU网络模型,手动调整参数直到BiGRU网络模型达到设定的预测效果,训练过程中,采用Adam优化器来自动调整BiGRU网络模型的学习率,利用均方误差作为BiGRU网络模型反向传播的损失函数,在对BiGRU网络模型训练的过程中提供稳定的误差梯度;

S44、保存训练后的BiGRU网络模型;

S45、对于保存的BiGRU网络模型,基于鱼鹰优化算法OOA,在给定范围内对BiGRU网络模型的参数进行自动寻优,实现参数的自配置。

[0028] S43中,引入基于模型预测误差变化的学习率调整机制来自动调整BiGRU网络模型的学习率,表示为:

$$\eta_{t+1} = \eta_t \cdot e^{-\alpha \cdot |\text{MSE}_t - \text{MSE}_{t-1}|};$$

式中, η_{t+1} 是调整后的学习率; η_t 是当前时刻的学习率; MSE_t 是当前时刻的均方误差; MSE_{t-1} 是上一时刻的均方误差; α 是调整速度的超参数; e 是自然常数;

同时,引入基于时间序列特性的损失函数作为均方误差损失函数的补充,基于时间序列特性的损失函数Time_Dependent_Loss表示为:

$$\text{Time_Dependent_Loss} = \sum_{i=1}^n [(y_i - \hat{y}_i)^2 + \delta \cdot |y_{i+1} - \hat{y}_i - \hat{y}_{i-1}|];$$

式中, y_i 是时间点*i*的实际值; y_{i+1} 是后一个时间点*i+1*的实际值; $\hat{y}_{i-1}$ 是前一个时间点*i-1*的预测值; $\hat{y}_i$ 是时间点*i*的预测值; δ 是调节系数,用于控制时间依赖性对总损失的贡献;*i*表示时间点;*n*是时间点的数量;基于时间序列特性的损失函数考虑前一个时间点*i-1*和后一个时间点*i+1*的值,从而捕捉时间序列的连续性和趋势;

并且,利用训练BiGRU网络模型过程中的训练集和验证集,动态调整Dropout层的Dropout率,表示为:

$$p_{\text{Dropout},t+1} = p_{\text{Dropout},t} + \beta \cdot (\text{Val_MSE}_t - \text{Train_MSE}_t);$$

式中, $p_{\text{Dropout},t}$ 是当前时刻的Dropout率; $p_{\text{Dropout},t+1}$ 是调整后的Dropout率; Val_MSE_t 是验证集上的均方误差; Train_MSE_t 是训练集上的均方误差; β 是调整步长。

[0029] S45中, 采用00A实现参数自配置的过程为:

S451、根据S43中手动调整的参数结果, 设定00A的搜索范围;

S452、在设定好的搜索范围内初始化鱼鹰种群中个体的位置;

S453、以均方根误差作为适应度函数, 计算每个个体的适应度值;

S454、根据鱼鹰捕食搜索策略更新个体位置, 若更新后的位置超出边界则将位置停留在边界处;

S455、判断更新后的个体适应度是否小于更新前的个体适应度, 若小于则更新个体的位置, 否则保留个体更新前的位置;

S456、判断是否达到结束条件, 若达到结束条件, 则返回搜索到的最优参数组合配置到BiGRU网络模型中, 否则进行下一轮的迭代搜索。

[0030] 将优化后的BiGRU网络模型集成到电池管理系统BMS中, 实现实时监控和预测。

[0031] 评估过程为:

使用测试集在不同评价指标上对本发明方法的预测性能进行评估, 具体步骤如下:

将测试集数据进行归一化处理。

[0032] 处理后的测试集数据输入到优化后的BiGRU网络模型中进行预测, 对预测出的老化数据进行反归一化处理, 得到电池的RUL预测结果。

[0033] 采用RMSE、平均绝对误差 (Mean Absolute Error, MAE)、平均绝对百分比误差 (Mean Absolute Percentage Error, MAPE) 以及决定系数 (R^2) 四个评价指标对模型的预测效果进行评估, 验证模型预测的准确性和鲁棒性。不同评价指标的计算公式分别如下:

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{k=1}^N |y(k) - \hat{y}(k)|^2};$$

$$\text{MAE} = \frac{1}{N} \sum_{k=1}^N |y(k) - \hat{y}(k)|;$$

$$\text{MAPE} = \frac{1}{N} \sum_{k=1}^N \left| \frac{y(k) - \hat{y}(k)}{y(k)} \right| \times 100\%;$$

$$R^2 = 1 - \frac{\sum_{k=1}^N [y(k) - \hat{y}(k)]^2}{\sum_{k=1}^N [y(k) - \bar{y}(k)]^2};$$

式中, $y(k)$ 和 $\hat{y}(k)$ 分别表示第k个循环的实际值和预测值, $\bar{y}(k)$ 表示实际的平均值; N 表示整个数据集中的循环次数。

[0034] 验证过程为:

验证时,采用马里兰大学电池数据集和实验获得的电池数据集。

[0035] 马里兰大学电池数据由高级生命周期工程中心Arbin BT2000电池实验系统对电池进行连续充放电实验获得,充放电过程在25℃的室温下进行。由正极材料制成的标称容量为1.1Ah和1.35Ah的CS2_33电池和CX2_37电池,在恒流-恒压(CC-CV)充电协议下独立充电。首先,电池以0.5C的固定电流速率充电,直到电压等于4.2V;然后将这些电池维持在4.2V的恒定电压下,直到电流降至50mA以下;接下来进行放电过程,CS2_33和CX2_37电池均以0.5C的恒流速率放电直至电压降至2.7V。

[0036] 为了能够准确获取反映电池状态的性能参数,本发明利用山东大学电动汽车动力电池研究课题组实验室配备的先进电池测试设备,构建了锂离子电池测试平台。该平台主要由Arbin BT-5HC动力电池测试仪、温控箱、测试电池以及上位机组成。使用Arbin测试仪进行电池的充放电循环测试,测试电池为18650电池,额定容量为1.55Ah,充电截止电压和放电截止电压分别为4.2V和3V。其中,M09电池和M10电池首先以2.5A的恒定电流进行充电,直至电压升为4.2V时切换为恒压充电,当电流小于0.05A或恒压充电时长满1小时后停止充电,电池静置1小时。接下来以2.5A的恒定电流对电池进行放电,直至电压降为3V时结束放电,静置电池1小时。如此进行循环的充放电实验,直至电池寿命终止。

[0037] 基于S1,从马里兰大学电池数据集和实验获得的电池数据集的全周期老化数据中提取出每轮循环的恒流充电时间(Constant Current Charging Time,CCCT)和恒压充电时间(Constant Voltage Charging Time,CVCT)。CCCT随着电池老化过程中容量的衰减而逐渐递减,而CVCT随着电池老化过程中容量的衰减而逐渐递增。此现象代表CCCT和CVCT与电池的老化程度存在关联,因此将二者作为RUL预测的健康因子(Health Factor,HF)。

[0038] 基于S2,根据CCCT曲线进一步提取出不同范围的等时间电压增量以及等电压上升时间,以此作为能够反应电池老化程度的不同HF。另外CCCT曲线中斜率最低点的时间及位置等信息也包含潜在的老化规律,这些信息也属于HF提取的考虑范围内。最终,基于不同的电池(马里兰大学电池数据集中的CS2_33、CX2_37和实验获得的电池数据集中的M09、M10),共选取出了十二个HF组成锂离子电池RUL预测的特征,表示为F1-F12,具体如表1所示。

[0039] 表1 不同电池选取出的健康因子HF

电池	CS2_33/CX2_37	M09/M10
F1	恒流充电时间	恒流充电时间
F2	恒压充电时间	恒压充电时间
F3	等时间电压增量 (3.8V_2400s)	等时间电压增量 (3.3V_2000s)
F4	等时间电压增量 (3.9V_2400s)	等时间电压增量 (3.4V_2000s)
F5	充电电压曲线斜率最低点斜率值	充电电压曲线斜率最低点斜率值
F6	充电电压曲线斜率最低点时间	充电电压曲线斜率最低点时间
F7	充电电压曲线斜率最低点电压值	充电电压曲线斜率最低点电压值
F8	等电压上升时间 (3.8-3.9V)	等电压上升时间 (3.25-3.35V)
F9	等电压上升时间 (3.9-4.0V)	等电压上升时间 (3.35-3.45V)
F10	等电压上升时间 (3.8-4.0V)	等电压上升时间 (3.25-3.45V)
F11	等电压上升时间 (3.9-4.1V)	等电压上升时间 (3.35-3.55V)
F12	等电压上升时间 (3.8-4.1V)	等电压上升时间 (3.25-3.55V)

[0040] 从电池电流、电压和时间数据中直接提取出的HF存在异常值和噪音,需要对该部分进行删除和过滤处理。首先,将提取出的每个HF分割成多个子集。然后根据 3σ 原则,将偏离均值超过3个标准差的数据点标记为异常值,删除该异常点对应循环次数的全部HF。之后,采用Savitzky-Golay滤波器,通过调整滑动窗口长度和多项式阶数来适应不同HF的特点,对异常值处理后的HF进行平滑处理,以减少数据的噪声和波动,使其更加平滑且易于分析。

[0041] 基于S3,考虑到已提取的HF组合中存在部分健康因子与电池的老化状态关联性弱,这些低相关性的HF会使模型难以从数据中捕捉到电池RUL的有效信息,从而降低预测的准确性。同时,相关性低的HF增加了模型的计算成本,导致训练时间增加,以及模型复杂度提高。采用基于过滤器方法的Pearson相关性分析对提取的所有HF进行关联度评估,计算出不同HF与电池老化状态之间的关联程度。根据Pearson相关系数的高低,选择出相关性最高的四个HF作为初步筛选后的特征,同时过滤掉其余HF。经计算,针对马里兰大学CS2_33和CX2_37电池、实验中的M09和M10电池,所提取HF的Pearson相关系数如表2所示。

[0042] 表2 不同电池健康因子反映电池老化状态的相关性系数

电池	CS2_33	CX2_37	M09	M10
F1	0.99806	0.99841	0.99955	0.99968
F2	-0.93408	-0.93196	-0.88863	-0.84399
F3	-0.96545	-0.97655	-0.91639	-0.92872
F4	-0.87102	-0.98228	-0.97097	-0.96607
F5	-0.99464	-0.99067	-0.76954	-0.91582
F6	0.79643	0.48864	0.64746	0.74234
F7	-0.95407	-0.89148	-0.43850	-0.69080
F8	0.97441	0.97363	0.98151	0.96532
F9	0.89023	0.99531	0.97132	0.95193
F10	0.98751	0.99604	0.97407	0.95519
F11	0.87859	0.99146	0.98169	0.99777
F12	0.98594	0.99714	0.98579	0.99683

[0043] 从表2中可以看出,F1、F3、F8、F10和F12这五个特征的整体相关性较高,对应四组电池的相关性评分均维持在了0.9以上。而代表充电电压曲线斜率最低点时间的F6相关程度不够理想,最低在CX2_37电池中仅为0.48864。经过Pearson相关性分析的筛选,CS2_33电池选用F1、F5、F10、F12作为过滤后的输入特征;CX2_37电池选用F1、F9、F10和F12作为过滤后的输入特征;M09电池选用F1、F8、F11和F12作为过滤后的输入特征;M10电池选用F1、F4、F11和F12作为过滤后的输入特征。

[0044] 高度相关或相似的HF会提高特征内部的冗余性,这种情况会对模型的预测效果产生负面影响。当模型使用过多相关的HF进行训练时,容易导致过拟合。这是由于模型会过度

关注训练数据中的冗余噪声或细微差异,而忽略了真正重要的老化模式和变化趋势。冗余HF会使得模型变得更加复杂且难以解释,同时冗余HF的存在意味着模型需要处理更多的HF,而这些HF可能并没有为预测性能带来实质性的提升,从而增加了模型的运行成本。采用序列前向搜索方法可以探索不同HF组合的特征空间,从单HF开始进行空间搜索,逐步添加至多HF子集。然后,根据模型的预测性能进行评估,找到最适合RUL预测的特征组合,提高模型性能的同时减少了特征空间的维度。经过Pearson相关性分析的过滤以及序列前向搜索方法的去冗余,最终通过融合特征筛选方法选择出用于电池RUL预测的融合特征如表3所示,表3中,√表示选择,×表示不选择。

[0045] 表3 锂离子电池RUL预测的融合特征

特征	CS2_33	CX2_37	M09	M10
F1	×	√	√	×
F2	×	×	×	×
F3	×	×	×	×
F4	×	×	×	√
F5	√	×	×	×
F6	×	×	×	×
F7	×	×	×	×
F8	×	×	√	×
F9	×	√	×	×
F10	√	×	×	×
F11	×	×	√	√
F12	√	√	×	×

[0046] 基于S4,搭建BiGRU网络模型,BiGRU的最终输出结果由正向GRU层和反向GRU共同决定,通过同时学习两个方向上的依赖关系,进一步增强模型对长期依赖信息的捕捉能力。

[0047] S451中,待配置的超参数分别为模型训练的迭代次数、模型训练的批次大小、第一层网络的神经元个数以及第二层网络的神经元个数,这些超参数组合到一起形成了一个待优化的四维数组,搜索范围的下限设定为[10,3,100,100],上限设定为[80,64,800,800]。

[0048] 鱼鹰完整的捕食过程包含探索阶段和捕捞阶段。在探索阶段,鱼鹰探测并追踪水下的鱼类的位置,鱼鹰追踪鱼群移动时会更新自己的位置。若鱼鹰的更新位置超出了边界,则将在边界上重新定义鱼鹰的新位置。在捕捞阶段,鱼鹰会将猎物带至相对安全的地方,改变自身的搜索范围,增加OOA的局部搜索能力和收敛性能。若鱼鹰的更新位置超出了边界,

则重新定义鱼鹰在边界上的新位置。

[0049] 多维特征相比于单维特征在能够提供更多老化信息的同时,对模型的信息捕捉能力要求也大大提高。从电池老化数据中提取的十二个HF组成能够实现电池RUL预测的全部特征,将其直接作为输入特征会提高模型预测的复杂度,从而更能考验模型对多维信息的捕捉能力。利用RMSE、MAE、MAPE和 R^2 四个评价指标来评估BiGRU模型与其他模型在全部特征上的预测效果,实验结果如表4所示,表4中,OOA-BiGRU即为本发明的优化后的BiGRU网络模型,参与对比的其他预测方法为BiGRU、GRU、RNN和CNN。

[0050] 表4 OOA-BiGRU与其他方法在不同评价指标上的对比结果

电池	预测方法	RMSE	MAE	MAPE (%)	R^2
CS2_33	OOA-BiGRU	0.0245	0.0205	2.5518	0.9516
	BiGRU	0.0369	0.0216	2.9038	0.8978
	GRU	0.0371	0.0329	3.9377	0.8965
	RNN	0.0427	0.0288	3.7531	0.8630
	CNN	0.0490	0.0386	4.8270	0.8195
CX2_37	OOA-BiGRU	0.0083	0.0070	0.7437	0.9898
	BiGRU	0.0179	0.0132	1.4504	0.9589
	GRU	0.0227	0.0167	1.8316	0.9334
	RNN	0.0232	0.0175	1.8955	0.9305
	CNN	0.0438	0.0307	3.3981	0.7533
M09	OOA-BiGRU	0.0123	0.0107	0.8789	0.9829
	BiGRU	0.0329	0.0262	2.1445	0.8721
	GRU	0.0379	0.0228	1.9366	0.8297
	RNN	0.0405	0.0261	2.2345	0.8060
	CNN	0.0448	0.0361	2.9375	0.7626
M10	OOA-BiGRU	0.0027	0.0023	0.1831	0.9982
	BiGRU	0.0109	0.0095	0.7421	0.9718
	GRU	0.0148	0.0128	1.0042	0.9476
	RNN	0.0188	0.0114	0.9217	0.9153
	CNN	0.0230	0.0194	1.4719	0.8733

[0051] 从表4中可以看出,CNN在所有电池上的预测结果均不够理想。除M10电池外,CNN在其余电池上预测的RMSE均高于0.04。这表示CNN主要用于处理静态网络结构的数据,而对于时间序列数据的建模能力相对较弱。对比CX2_37和M10电池,RNN的容量预测效果比CNN更好。其中,在CX2_37中RNN的RMSE和MAE比CNN低了0.0206和0.0132,而在M10中RNN的MAPE比RNN低了0.55。此外,RNN在其他两节电池的评价指标上相比于CNN也有略微领先,体现出RNN更适合处理序列数据中的时序信息。对比GRU和RNN的预测效果,GRU在所有电池的RMSE和 R^2 评价指标上均要优于RNN。此结果验证了GRU相比RNN更具有预测的稳定性,得益于GRU独特

的门控机制能够有效缓解RNN的梯度消失和梯度爆炸问题。

[0052] BiGRU在GRU的基础上增加双向结构,在处理多特征输入预测方面的能力要优于传统的GRU。数据结果显示,BiGRU在四个电池的RMSE上相比于GRU平均降低了15.3%,同时在MAE和MAPE上分别平均降低了16.5%和15.6%。这表明BiGRU相比单向的GRU具有更好的信息获取能力、特征表示能力和序列建模能力,在处理噪声和干扰方面更具有鲁棒性。综合来看,BiGRU在基于全部特征的预测上表现出最好的预测效果,因此选用BiGRU模型进行特征筛选和参数配置上的优化,最大程度地提高模型的预测精度。

[0053] 经过计算可以得出,CS2_33电池中00A-BiGRU相较于BiGRU在RMSE、MAE和MAPE评价指标上分别降低了33.6%、5.1%和12.1%。在CX2_37中三个指标分别降低了53.6%、47.0%和48.7%。而在M09和M10中三个指标得到了进一步的降低,在M09中降低了62.6%、59.2%和59.0%,在M10中降低了75.2%、75.8%和75.3%。所有电池上经过00A参数优化的BiGRU模型,在预测性能上均得到了不同程度的提高,意味着00A有效地提升了模型预测的准确性和稳定性。另外,通过 R^2 数据可以观察到有了00A同样能够提高BiGRU模型进行电池老化预测的拟合度,最低在CX2_37电池中提高了3.1%,最高在M09电池中提高了11.1%。拟合度的提高意味着00A-BiGRU模型能够更有效地捕捉输入特征与目标变量之间的关系,能更好地描述数据之间的复杂关系。这有助于揭示输入特征和目标变量之间的内在联系,同时模型的泛化能力也随之提高。

[0054] 采用00A-BiGRU模型(即为本发明采用00A优化后的BiGRU网络模型)对电池RUL进行预测,分别对基于全部特征预测、基于过滤特征(Filtered Features,FIF)预测以及基于融合特征(Fusion Features,FUF,即为本发明方法)预测的锂离子电池RUL预测效果进行比较。基于FIF的模型预测结果相较于基于全部特征预测更加贴合实际曲线,反映出经过过滤器筛选后的FIF在一定程度上提高了模型预测的准确性。基于本发明FUF的预测实现了三种特征中的最好预测效果,其在EOL处相比其他两种特征预测结果更接近真实值,说明基于FUF的方法能实现更精准的RUL预测。基于全部特征下以及FIF的模型预测误差较为离散,而基于FUF的00A-BiGRU模型预测产生的误差点除个别点浮动外基本聚集在0附近,展示出了本发明方法具有较高的稳定性和预测精度。

[0055] 通过老化趋势预测分析,FIF-00A-BiGRU对比00A-BiGRU在模型预测准确度上得到了提高,而FUF-00A-BiGRU相较于FIF-00A-BiGRU在原有的基础上更进一步提升了预测的有效性,以此说明FUF比FIF和全部特征更能反映电池的老化状态。采用FUF预测相较于其他两个特征的对对应曲线更加接近于原始真实值,代表其最终预测出的RUL精度也要高于另外两种方法,这得益于FUF方法提取特征的适应性和灵活性。

[0056] 对于不同的数据集或预测任务,FUF能够通过融合筛选过程找到最优的特征组合。FUF有效避免了噪音和冗余特征的干扰,从而提高了整体的预测精度和稳定程度,有着更高的预测精度和高度的一致性。FUF方法中对FIF内的冗余项做到了有效剔除,提高了模型的预测精度。

[0057] 基于不同特征的RUL预测结果与误差数据如表5所示。可以看出,表5中所有模型均实现了较为精准的RUL预测。但本发明方法(表5中的FUF-00A-BiGRU)相较于FIF-00A-BiGRU和基于全部特征地00A-BiGRU在CS2_33、CX2_37和M09电池的RUL预测精度上实现了进一步的提高。在M10电池中,FUF-00A-BiGRU模型实现了RUL的零误差预测。实际数据证明,基于

FUF-00A-BiGRU的模型满足了高精度RUL预测的要求,且保障了预测方法的普适性。

[0058] 表5 00A-BiGRU模型在不同特征上的RUL预测结果及误差

电池	预测方法	RUL	RUL 误差
CS2_33	Real	568	0
	FUF-00A-BiGRU	569	1
	FIF-00A-BiGRU	571	3
	00A-BiGRU	572	4
CX2_37	Real	979	0
	FUF-00A-BiGRU	980	1
	FIF-00A-BiGRU	987	8
	00A-BiGRU	988	10
M09	Real	380	0
	FUF-00A-BiGRU	381	1
	FIF-00A-BiGRU	383	3
	00A-BiGRU	383	3
M10	Real	337	0
	FUF-00A-BiGRU	337	0
	FIF-00A-BiGRU	339	2
	00A-BiGRU	340	3

[0059] 实验结果表明,本发明在不同锂离子电池上均展现了良好的RUL预测效果,验证了本发明的准确性和鲁棒性。




图 1